

TUGAS MANDIRI
FUNDAMENTALS OF DATA MINING



Nama : Desi Sumiati
Npm : 220210155
Dosen : Erlin Elisa, S.kom., M.Kom
Program Studi : Teknik Informatika

FAKULTAS TEKNIK DAN KOMPUTER
TEKNIK INFORMATIKA UNIVERSITAS
PUTRA BATAM
2024/2025

LAPORAN ANALISIS DATA SPOTIFY MENGGUNAKAN ALGORITMA C4.5

1. Deskripsi Dataset

- **Sumber dataset:** [Kaggle.com https://www.kaggle.com/datasets/wardabilal/spotify-global-music-dataset-20092025](https://www.kaggle.com/datasets/wardabilal/spotify-global-music-dataset-20092025)
- **Jumlah record:** 32.833 data lagu Spotify
- **Jumlah atribut:** 23 atribut awal (28 setelah feature engineering)
- **Tipe data:** Numerik (13 atribut) dan Kategorikal (10 atribut)
- **Target/label:** popularity_category (Low, Medium, High) berdasarkan track_popularity
- **Permasalahan yang ingin diselesaikan:**

"Dataset ini terdiri dari 32.833 data lagu Spotify dengan 23 atribut audio features dan metadata untuk memprediksi tingkat popularitas lagu (Low/Medium/High) berdasarkan karakteristik musik seperti danceability, energy, loudness, dan lainnya."

2. Persiapan Data & Preprocessing

Langkah Preprocessing yang Dilakukan:

1. Data Cleaning:

- Missing values hanya 5 data (<0.02%) pada kolom track_name, track_artist, track_album_name
- Diisi dengan mode (nilai paling sering)
- Tidak ada data duplikat ditemukan

2. Feature Engineering:

- Membuat popularity_category dari track_popularity:
 - **Low:** 0-33 (18.373 data, 56%)
 - **Medium:** 34-66 (11.493 data, 35%)
 - **High:** 67-100 (2.967 data, 9%)
- Konversi duration_ms ke duration_min
- Log transform untuk instrumentalness dan liveness (skewness > 2)

- Encoding variabel boolean mode menjadi mode_encoded

3. Feature Selection:

- Drop kolom ID dan nama karena terlalu unik
- Fokus pada audio features dan metadata numerik

4. Scaling: StandardScaler untuk fitur numerik

5. Split Data: 80% training (26.266 data), 20% testing (6.567 data)

Tabel Ringkasan Preprocessing:

Aspek	Sebelum	Sesudah
Jumlah Record	32.833	32.833
Jumlah Fitur	23	28
Missing Values	15 (0.05%)	0
Distribusi Kelas	Imbalanced (56%/35%/9%)	Balanced dengan SMOTE
Tipe Data Target	Numerik (0-100)	Kategorikal (3 kelas)

Distribusi Data Train vs Test:

Set Data	Jumlah Data	Persentase	Distribusi Kelas (L/M/H)
Training	26.266	80%	14.698 / 9.194 / 2.374
Testing	6.567	20%	3.675 / 2.299 / 593
Total	32.833	100%	18.373 / 11.493 / 2.967

❏ Analisis Statistik & Visualisasi

Statistik Deskriptif Dataset:

- **track_popularity**: Mean = 42.5, Std = 25.0, Range = 0-100
- **danceability**: Mean = 0.655, Distribusi normal dengan sedikit left skew (-0.5)
- **energy**: Mean = 0.699, Distribusi normal

- **loudness**: Mean = -6.72 dB, Left skewed (-1.36) - kebanyakan lagu tidak terlalu keras
- **duration_ms**: Mean = 225.8 detik (3:46), Std = 59.8 detik

Distribusi Target/Label:

Low: 18.373 data (56.0%)

Medium: 11.493 data (35.0%)

High: 2.967 data (9.0%)

Insight: Dataset sangat imbalanced dengan kelas High hanya 9%.

Heatmap Korelasi:

<https://via.placeholder.com/600x400?text=Heatmap+Correlation>

Insight dari Heatmap:

1. **energy** dan **loudness** berkorelasi positif kuat (0.76) - lagu energik cenderung lebih keras
2. **acousticness** berkorelasi negatif dengan **energy** (-0.67) dan **loudness** (-0.64)
3. **valence** (positiveness) berkorelasi positif dengan **danceability** (0.54)
4. **track_popularity** memiliki korelasi rendah dengan semua fitur (<0.1), tertinggi dengan **acousticness** (0.085)

Visualisasi Pendukung:

Histogram Fitur Numerik:

- **danceability**: Distribusi normal dengan puncak di 0.65-0.75
- **energy**: Distribusi sedikit left skewed, kebanyakan lagu memiliki energy tinggi
- **loudness**: Bimodal distribution dengan puncak di -8 dB dan -5 dB

Boxplot per Kategori Popularitas:

- Lagu **High popularity**:

- danceability lebih tinggi (median 0.72 vs 0.67)
- loudness lebih keras (median -5.8 dB vs -6.2 dB)
- duration lebih pendek (median 3:30 vs 3:45)

Insight Visual:

1. Lagu populer cenderung lebih "danceable" dan lebih keras
2. Durasi optimal untuk popularitas tinggi sekitar 3-4 menit
3. Tidak ada perbedaan signifikan dalam energy antar kategori popularitas

Pemilihan dan Penerapan Algoritma

Nama Algoritma: C4.5 (Decision Tree dengan entropy)

Alasan Pemilihan:

1. **Data Kategorikal:** C4.5 efektif menangani data kategorikal dan numerik
2. **Interpretabilitas:** Mudah diinterpretasi dan divisualisasikan (aturan if-else)
3. **Non-linear:** Dapat menangkap hubungan non-linear antar fitur
4. **Feature Importance:** Dapat mengidentifikasi fitur paling berpengaruh
5. **Robust terhadap noise:** Cocok untuk data audio features yang mungkin noisy

Parameter Utama yang Digunakan:

```
DecisionTreeClassifier(
    criterion='entropy',    # C4.5 menggunakan entropy
    max_depth=10,          # Membatasi kompleksitas
    min_samples_split=20,   # Minimum sampel untuk split
    min_samples_leaf=10,    # Minimum sampel di leaf
    random_state=42,
    class_weight='balanced' # Handling imbalance
)
```

Algoritma yang Diuji:

Algoritma	Library Python	Tujuan
C4.5 (Decision Tree)	sklearn.tree	Klasifikasi multi-kelas & interpretability
Random Forest	sklearn.ensemble	Benchmark & ensemble method
K-Nearest Neighbors	sklearn.neighbors	Baseline & similarity-based
Gradient Boosting	sklearn.ensemble	Advanced boosting method

Pengujian dan Evaluasi Model

Metode Evaluasi (Klasifikasi Multi-Kelas):

- Accuracy, Precision (weighted), Recall (weighted), F1-Score (weighted)
- Confusion Matrix, Classification Report

Tabel Hasil Klasifikasi:

Algoritma	Accuracy	Precision	Recall	F1-Score
C4.5 (Tuned)	0.648	0.645	0.648	0.646
Random Forest	0.651	0.649	0.651	0.649
Gradient Boosting	0.639	0.636	0.639	0.637
K-Nearest Neighbors	0.592	0.588	0.592	0.589
C4.5 (Baseline)	0.632	0.629	0.632	0.630